

论文：《SigLIP 2: Multilingual Vision-Language Encoders with Improved Semantic Understanding, Localization, and Dense Features》

论文链接：<https://arxiv.org/pdf/2502.14786>

GitHub：[https://github.com/google-research/big\\_vision](https://github.com/google-research/big_vision)

## 1. 背景

SigLIP2主要改进：

- 训练目标：在SigLIP的图像-文本sigmoid对比损失的基础上，结合了 LocCa 的基于解码器的预训练以及 SILC 和 TIPS 中的自蒸馏和掩码预测任务。
- 隐式蒸馏：并且通过主动样本选择进行隐式蒸馏，提升小型模型的性能。
- 可变分辨率：SigLIP2包含一个 NaFlex 变体，支持多种分辨率并保留图像的原始长宽比。

通过这些改进，SigLIP 2模型在所有模型规模上的核心能力均优于SigLIP，包括零样本分类、图像-文本检索，以及在提取视觉-语言模型（VLMs）的视觉表示时的迁移性能。

## 2. SigLIP2

模型架构上还是Image Encoder+Text Encoder的架构，但是训练架构上有三个任务：




Figure 1 | SigLIP 2 adds the captioning-based pretraining from LocCa [62] as well as self-distillation and masked prediction from SILC [45] and TIPS [38] (during the last 20% of training) to the sigmoid loss from SigLIP [71]. For some variants, the recipe additionally involves fine-tuning with data curation [61] or adaptation to native aspect ratio and variable sequence length [6, 12].

## 2.1 Sigmoid Loss

这一部分和SigLIP是一样的。即SigLIP 通过将每个图像嵌入与小批量中的每个文本嵌入组合，创建二元分类问题，并通过逻辑回归（sigmoid 损失）训练嵌入，以分类匹配和不匹配的对。

## 2.2 LocCa Loss

对于 LocCa，在未池化的视觉编码器表示（在应用 MAP 头之前）上附加了一个带有交叉注意力的标准 Transformer 解码器。解码器的结构与文本编码器相似，但增加了交叉注意力层，并将层数减少了一半。除了图像描述生成，LocCa还训练自动指称表达预测和基础描述生成。前者是预测描述特定图像区域的字幕的边界框坐标，而后者是给定边界框坐标预测区域特定的字幕。区域与字幕的配对通过首先从替代文本中提取n-gram，然后使用OWLv2中的方法进行开放词汇检测来自动标注。此外，我们使用PaLI中固定的对象类别集，而不是n-gram。对于每个示例，解码器被训练以预测所有三个目标（相当于三次解码器前向传递）。字幕生成目标以50%的概率通过并行预测进行预测，即所有字幕标记从掩码标记中并行预测，不使用因果注意力掩码。最后，为了减少由于大词汇量导致的内存消耗，实现分块版本的解码器损失。

## 2.3 SILC/TIPS Loss

SILC和TIPS通过自蒸馏和掩码预测损失进行局部到全局的对应学习，以提升（未池化）特征表示的局部语义。这种表示通常用于像分割、深度估计等密集预测任务。

第一个项是来自SILC的局部到全局一致性损失，其中视觉编码器作为学生网络，仅获取训练图像的部分（局部）视图，并被训练来匹配从完整图像得出的教师表示。这个辅助匹配任务在一个用单独的MLP头计算的高维特征空间中执行。通常，教师的参数通过对学生参数在之前迭代中的指数移动平均（EMA）获得。我们依赖一个全局（教师）视图和8个局部（学生）视图，其他方面则遵循SILC中的增强、损失和超参数。

第二个损失项是来自TIPS的掩码预测目标。我们在学生网络中将50%的嵌入图像块替换为掩码标记，并训练学生在被掩盖的位置上匹配教师的特征。该损失的定义与第一个项（即一致性损失）相同，但应用于每个图像块的特征，而不是池化的图像级表示。此外，学生和教师都看到相同的全局视图（学生的视图会有掩码处理）。

在训练完成的80%时加入这些损失，将教师的参数初始化为学生的参数，而其余附加参数（如头部、掩码标记及相应的优化器参数）则随机初始化。我们使用原始图像计算上一节中的SigLIP和LocCa损失，并在额外增强的视图上应用附加损失。这样做是为了确保数据增强不会对图像-文本对齐产生负面影响，这也是SILC的建议。第一个和第二个损失项的权重分别设为1和0.25。此外，为了平衡模型在全局/语义和密集任务上的质量，我们对这两个损失项分别按0.25、0.5、1.0和0.5的系数重新加权，适用于B、L、So400m和g模型大小。

## 2.4 可变尺寸和分辨率(NaFlex)

针对多分辨率输入，SigLIP 2 采用了 NaFlex 模型，它结合了不同分辨率和保留图像原生纵横比的思想。该模型在处理图像时，首先调整输入图像的大小，以确保其高度和宽度在调整后是patch大小的倍数，同时尽量减少纵横比的失真。通过这种方法，可以使用适合不同类型图像的适当分辨率，并在任务中降低失真对性能的影响。

此外，NaFlex 支持多种预定义的序列长度，使得模型能够更有效地处理不同的输入类型。在训练阶段，模型从默认检查点开始，调整训练来适应变化的纵横比和分辨率，从而实现更好的处理和性能。

# 3. 实验

### 3.1 零样本分类和检索

SigLIP 2在零样本分类（ImageNet、ObjectNet、ImageNetv2、ImageNet Real）和图文检索基准上的性能都优于SigLIP和其他（开放权重）基准。

需要注意的是，DFN在这些基准上最接近SigLIP 2，它使用在ImageNet、COCO和Flickr上微调的网络作为过滤器来提高数据质量。

由于蒸馏的原因，SigLIP2在B尺寸模型上对基准的改进尤为显著。此外，我们观察到常见的缩放趋势是图像分辨率和模型大小的函数。

| ViT   | Res. | Seq. | Model         | ImageNet-1k |      |      |        |      | COCO |      | Flickr |      | XM3600 |      |
|-------|------|------|---------------|-------------|------|------|--------|------|------|------|--------|------|--------|------|
|       |      |      |               | val         | v2   | Real | ObjNet | 10s. | T→I  | I→T  | T→I    | I→T  | T→I    | I→T  |
| B/32  | 224  | 49   | MetaCLIP [66] | 67.7        | 59.6 | –    | 52.8   | –    | 46.6 | –    | 72.9   | –    | –      | –    |
|       | 256  | 64   | OpenCLIP [27] | 72.8        | 64.8 | –    | 59.6   | –    | 39.9 | 57.9 | 64.9   | 84.8 | –      | –    |
|       |      |      | SigLIP 2      | 74.0        | 66.9 | 81.4 | 66.1   | 66.6 | 47.2 | 63.7 | 75.5   | 89.3 | 38.3   | 49.0 |
| B/16  | 224  | 196  | CLIP [50]     | 68.3        | 61.9 | –    | 55.3   | –    | 33.1 | 52.4 | 62.1   | 81.9 | –      | –    |
|       |      |      | OpenCLIP [27] | 70.2        | 62.3 | –    | 56.0   | –    | 42.3 | 59.4 | 69.8   | 86.3 | –      | –    |
|       |      |      | MetaCLIP [66] | 72.4        | 65.1 | –    | 60.0   | –    | 48.9 | –    | 77.1   | –    | –      | –    |
|       |      |      | EVA-CLIP [57] | 74.7        | 67.0 | –    | 62.3   | –    | 42.2 | 58.7 | 71.2   | 85.7 | –      | –    |
|       |      |      | SigLIP [71]   | 76.2        | 69.5 | 82.8 | 70.7   | 69.9 | 47.2 | 64.5 | 77.9   | 89.6 | 22.4   | 29.3 |
|       |      |      | DFN [19]      | 76.2        | 68.2 | –    | 63.2   | –    | 51.9 | –    | 77.3   | –    | –      | –    |
|       |      |      | SigLIP 2      | 78.2        | 71.4 | 84.8 | 73.6   | 72.1 | 52.1 | 68.9 | 80.7   | 93.0 | 40.3   | 50.7 |
|       | 256  | 256  | SigLIP [71]   | 76.7        | 70.1 | 83.1 | 71.3   | 70.3 | 47.4 | 65.1 | 78.3   | 91.1 | 22.5   | 29.9 |
|       |      |      | SigLIP 2      | 79.1        | 72.5 | 85.4 | 74.5   | 73.1 | 53.2 | 69.7 | 81.7   | 94.4 | 40.7   | 51.0 |
|       | 384  | 576  | SigLIP [71]   | 78.6        | 72.0 | 84.6 | 73.8   | 72.7 | 49.7 | 67.5 | 80.7   | 92.2 | 23.3   | 30.3 |
|       |      |      | SigLIP 2      | 80.6        | 73.8 | 86.2 | 77.1   | 74.7 | 54.6 | 71.4 | 83.8   | 94.9 | 41.2   | 51.6 |
|       | 512  | 1024 | SigLIP [71]   | 79.2        | 72.9 | 84.9 | 74.8   | 73.3 | 50.4 | 67.6 | 81.6   | 92.5 | 23.5   | 30.5 |
|       |      |      | SigLIP 2      | 81.2        | 74.5 | 86.7 | 77.8   | 75.2 | 55.2 | 71.2 | 84.5   | 95.5 | 41.4   | 52.0 |
| L/14  | 224  | 256  | OpenCLIP [27] | 74.0        | 61.1 | –    | 66.4   | –    | 46.1 | 62.1 | 75.0   | 88.7 | –      | –    |
|       |      |      | CLIP [50]     | 75.5        | 69.0 | –    | 69.9   | –    | 36.5 | 56.3 | 65.2   | 85.2 | –      | –    |
|       |      |      | MetaCLIP [66] | 79.2        | 72.6 | –    | 74.6   | –    | 55.7 | –    | 83.3   | –    | –      | –    |
|       |      |      | CLIP-v2 [33]  | 79.7        | 72.8 | –    | 71.1   | –    | 46.3 | 64.1 | 73.0   | 89.1 | –      | –    |
|       |      |      | EVA-CLIP [57] | 79.8        | 72.9 | –    | 75.3   | –    | 47.5 | 63.7 | 77.3   | 89.7 | –      | –    |
|       |      |      | DFN [19]      | 82.2        | 75.7 | –    | 74.8   | –    | 59.6 | –    | 84.7   | –    | –      | –    |
| L/16  | 256  | 256  | SigLIP [71]   | 80.5        | 74.2 | 85.9 | 77.9   | 76.8 | 51.2 | 69.6 | 81.3   | 92.0 | 30.9   | 40.1 |
|       |      |      | SigLIP 2      | 82.5        | 76.8 | 87.3 | 83.0   | 78.8 | 54.7 | 71.5 | 84.1   | 94.5 | 46.5   | 56.5 |
|       | 384  | 576  | SigLIP [71]   | 82.1        | 75.9 | 87.1 | 80.9   | 78.7 | 52.8 | 70.5 | 82.6   | 92.9 | 31.4   | 39.7 |
|       |      |      | SigLIP 2      | 83.1        | 77.4 | 87.6 | 84.4   | 79.5 | 55.3 | 71.4 | 85.0   | 95.2 | 47.1   | 56.3 |
|       | 512  | 1024 | SigLIP 2      | 83.5        | 77.8 | 87.7 | 84.6   | 79.6 | 55.2 | 72.1 | 85.3   | 95.8 | 47.4   | 56.7 |
| So/14 | 224  | 256  | SigLIP [71]   | 82.2        | 76.0 | 87.1 | 80.5   | 78.2 | 50.8 | 69.0 | 76.6   | 90.7 | 16.0   | 22.8 |
|       |      |      | SigLIP 2      | 83.2        | 77.7 | 87.8 | 84.6   | 79.5 | 55.1 | 71.5 | 84.3   | 94.6 | 47.9   | 57.5 |
|       | 384  | 729  | SigLIP [71]   | 83.2        | 77.1 | 87.5 | 82.9   | 79.4 | 52.0 | 70.2 | 80.5   | 93.5 | 17.8   | 26.6 |
|       |      |      | SigLIP 2      | 84.1        | 78.7 | 88.1 | 86.0   | 80.4 | 55.8 | 71.7 | 85.7   | 94.9 | 48.4   | 57.5 |
| So/16 | 256  | 256  | mSigLIP [71]  | 80.8        | 74.1 | 86.1 | 79.5   | 77.1 | 49.4 | 68.6 | 80.0   | 92.1 | 50.0   | 62.8 |
|       |      |      | SigLIP 2      | 83.4        | 77.8 | 87.7 | 84.8   | 79.7 | 55.4 | 71.5 | 84.4   | 94.2 | 48.1   | 57.5 |
|       | 384  | 576  | SigLIP 2      | 84.1        | 78.4 | 88.1 | 85.8   | 80.4 | 56.0 | 71.2 | 85.3   | 95.9 | 48.3   | 57.5 |
|       | 512  | 1024 | SigLIP 2      | 84.3        | 79.1 | 88.1 | 86.2   | 80.5 | 56.0 | 71.3 | 85.5   | 95.4 | 48.3   | 57.6 |
| H/14  | 224  | 256  | MetaCLIP [66] | 80.5        | 74.1 | –    | 76.5   | –    | 57.5 | –    | 85.0   | –    | –      | –    |
|       |      |      | DFN [19]      | 83.4        | 77.3 | –    | 76.5   | –    | 63.1 | –    | 86.5   | –    | –      | –    |
| g/16  | 256  | 256  | SigLIP 2      | 84.5        | 79.2 | 88.3 | 87.1   | 82.1 | 55.7 | 72.5 | 85.3   | 95.3 | 48.2   | 58.2 |
|       | 384  | 576  | SigLIP 2      | 85.0        | 79.8 | 88.5 | 88.0   | 82.5 | 56.1 | 72.8 | 86.0   | 95.4 | 48.6   | 57.9 |

Table 1 | Zero-shot classification, 10-shot (10s) classification (on the validation set), and retrieval performance (recall@1) of SigLIP 2 along with several baselines. SigLIP 2 outperforms the baselines—often by a large margin—despite being multilingual. Note that DFN [19] relies on a data filtering network fine-tuned on ImageNet, COCO, and Flickr.

### 3.2 SigLIP2作为v1m的视觉编码器

视觉编码器如CLIP和SigLIP的一个常见用途是为VLMs提取视觉表示。通常的做法是将预训练的视觉编码器与预训练的LLM结合，并在丰富的视觉语言任务混合上进行多模态训练。

具体来说，将SigLIP 2视觉编码器和基准与Gemma2 2B LLM结合，并在包含字幕、OCR、定向字幕、视觉问答、检测和实例分割的Stage 1训练集上的5000万例子上训练LLM。我们保持视觉编码器冻结（这对质量几乎没有影响）并减少训练时间以反映典型的开放模型使用情况。生成的VLM随后在广泛的下游任务上进行微调，使用相关文献中的迁移设置。为了理解输入分辨率的影响，我们在分辨率224或256（对应于分别提取256个图像token的14和16的patch大小的模型）和384px上进行实验，但与相关文献不同的是，我们在384px上重复Stage 1，而不是从224px变体开始。

总体来看，SigLIP 2在各个分辨率和模型大小上明显优于SigLIP。对于L尺寸的视觉编码器，SigLIP 2也优于最近发布的AIMv2模型。




Figure 4 | Comparison of different vision encoders after training a Gemma 2 LLM for 50M steps with a frozen vision encoder (PaliGemma [7] stage 1), followed by fine-tuning the VLM on individual datasets (PaliGemma stage 3). SigLIP 2 performs better than SigLIP and AIMv2 [20] for different model sizes and resolutions. Same data as in Table 6.